# 数据库系统

# 数据存储与访问路径(1)

陈世敏

（中科院计算所）

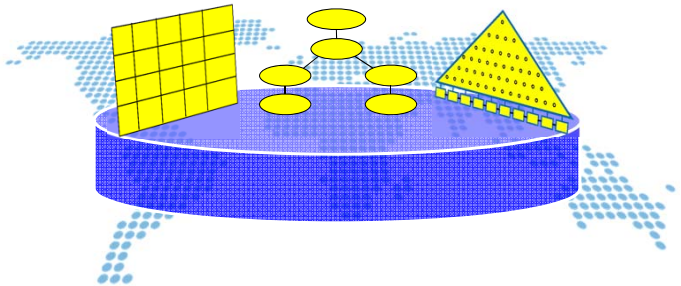

## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理

 

## 通常的系统为典型的Client / Server

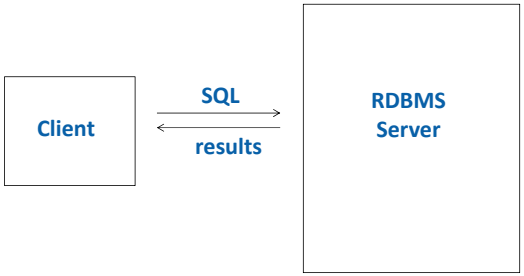


 

## RDBMS的系统架构(单机)

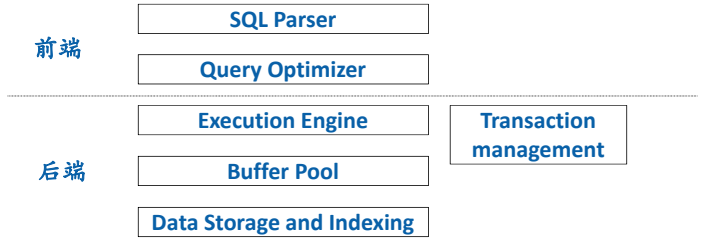


 

## RDBMS的系统架构

- SQL 语句的程序➔解析好的内部表达
  （例如：parsing tree）
  - 语法解析，语法检查，表名、列名、类型检查

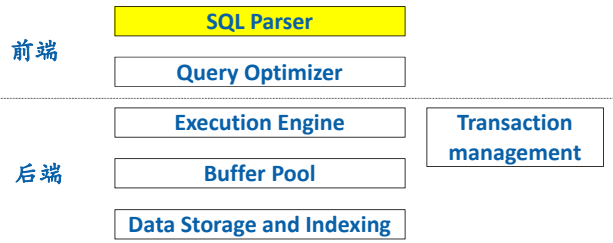




## RDBMS的系统架构

- SQL内部表达➔Query Plan (执行方案)
  - 产生可行的query plan
  - 估计query plan的运行时间和空间代价
  - 在多个可行的query plans中选择最佳的query plan

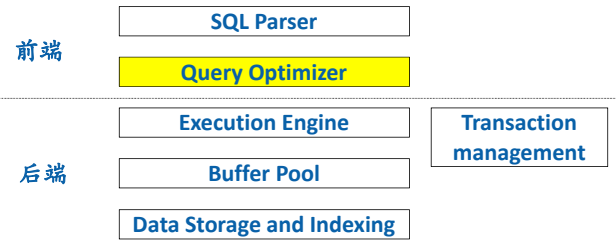




## RDBMS的系统架构

- Data storage and indexing
  - 如何在硬盘上存储数据
  - 如何高效地访问硬盘上的数据
  - ☞最后一节课会介绍内存数据库

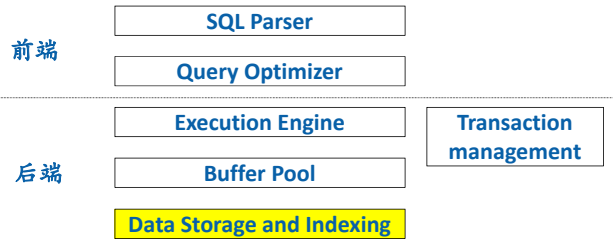




## RDBMS的系统架构

- Buffer pool: 在内存中缓存硬盘的数据
  - 数据重复使用
  - 优化写操作

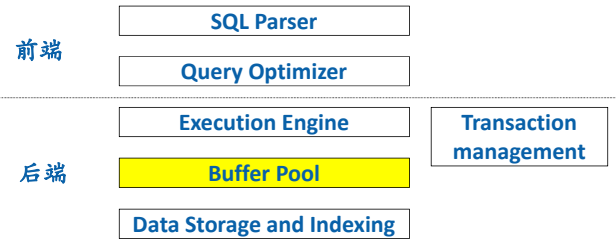

## RDBMS的系统架构

- query plan➔SQL语句的结果
  - 根据query plan，完成相应的运算和操作
  - 数据访问
  - 关系型运算的实现

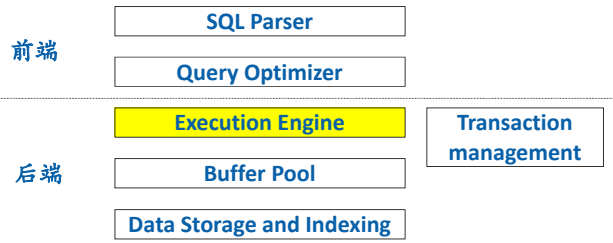




## RDBMS的系统架构

- Transaction management：事务管理
  - 目标是实现ACID
    - Atomicity, Consistency, Isolation, Durability
  - 进行logging写日志，locking加锁
  - 保证并行transactions事务的正确性

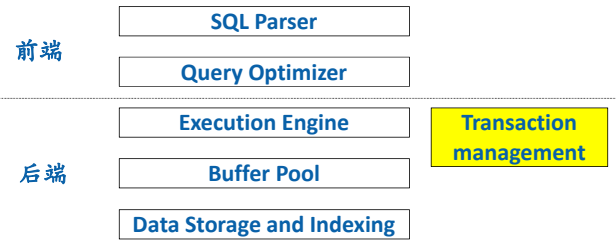




## RDBMS的系统架构(单机)

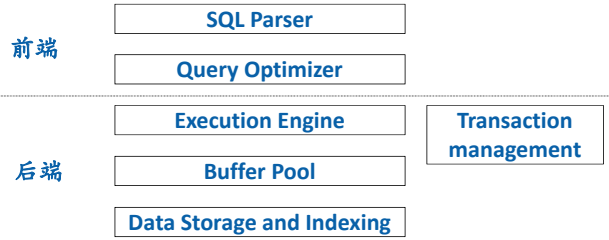




## 内存数据库的系统架构(单机)

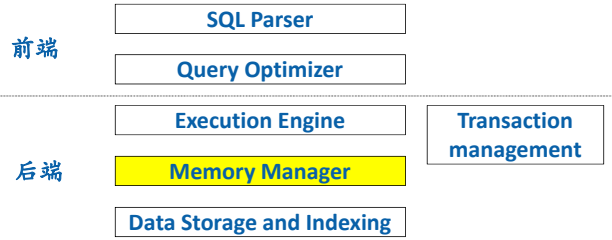


- 数据主要存储在内存

## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
  - 存储层次
  - 存储介质：磁盘、固态硬盘等
  - 磁盘阵列
  - 操作系统支持
  - 存什么？
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理

 

## 存储层次结构

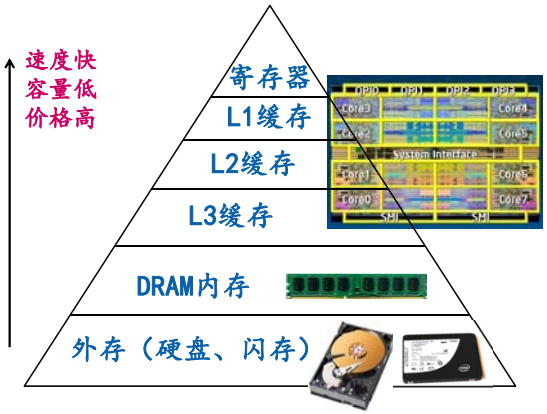


 

## 存储层次间传输数据

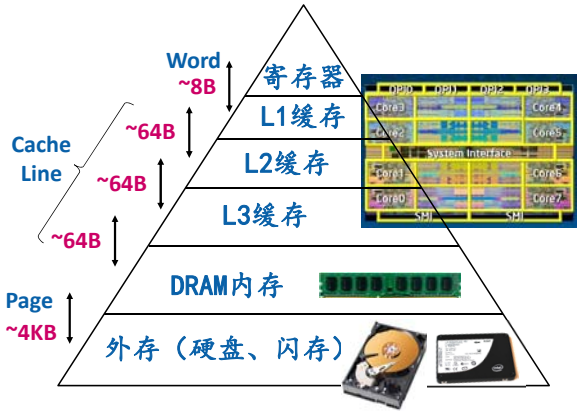


 

## 存储层次比较(中档服务器)

| | 容量 | 单位价格 | 读写延时 | 读写带宽 |
|---|---|---|---|---|
| 寄存器 (Register) | 100B~1KB | $100/KB | <1ns | - |
| 高速缓存 (Cache, SRAM) | ~10MB | $10/MB | 1~10ns | ~TB/s |
| 内存 (Memory, DRAM) | 10~100GB | $10/GB | 50~100ns | ~10GB/s |
| 固态硬盘 (SSD, Flash) | 100~1TB | $0.5~$1/GB | 读~100us<br>写100~1ms | 300MB~1GB/s |
| 硬盘 (HDD) | 10~100TB | $0.05/GB | ~10ms | ~100MB/s |

 

## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
  - 存储层次
  - 存储介质：磁盘、固态硬盘等
  - 磁盘阵列
  - 操作系统支持
  - 数据与索引
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理



## 硬盘（HDD, Hard Disk Drive）

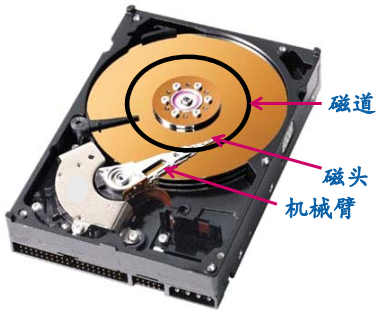


- 盘片(Platter)是磁存储介质，通常1~3片
  - 直径5吋，3.5吋（台式机），2.5吋（笔记本/刀片机）
- 正常工作时，盘片匀速旋转(spin)，rpm (round per minute)
  - 5400rpm (笔记本), 7200rpm (台式机), 10000rpm (服务器), 15000rpm



## 硬盘（HDD）

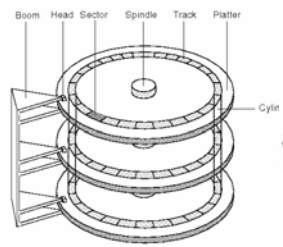


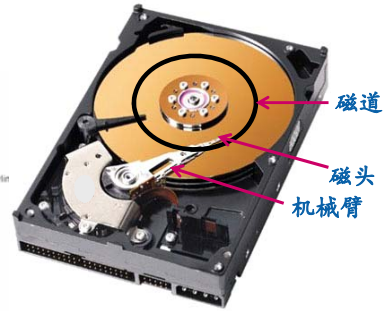


- 盘片(Platter)分成许多的同心圆
  - 每个同心圆称作一个磁道（track），（2008年：$10^5$磁道/盘）
  - 多个盘片同一位置的磁道称作一个柱面（cylinder）
  - 每个磁道进一步分成许多扇区（sector）
  - 每个扇区可以存储512B数据



## 硬盘（HDD）

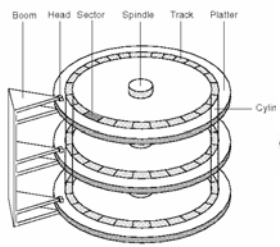


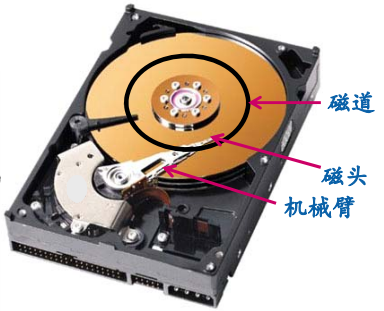


- 磁头
  - 盘片高速旋转，在磁头和盘片之间形成一个空气薄膜
  - 磁头悬浮在盘片上
  - 如果磁头和盘片接触，就会破坏盘面
    - 例如，突然断电，或者震动

## 硬盘访问

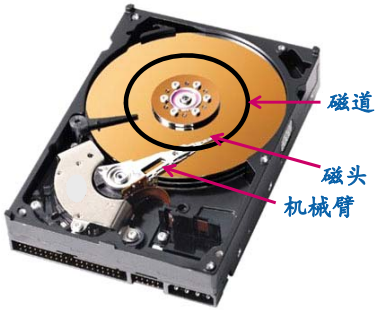


- 给定一个具体的track和sector，访问过程如下
  - Seek：移动磁头，放置到相应的cylinder上
  - Rotational delay：等待sector旋转到磁头之下
  - Transfer：读/写sector的内容
- 访问时间=$T_{seek}$ + $T_{rotate}$ + $T_{transfer}$



## 随机访问vs.顺序访问

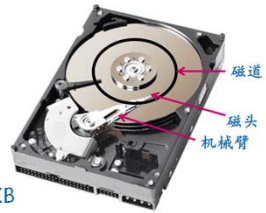


- 访问时间=$T_{seek}$ + $T_{rotate}$ + $T_{transfer}$
- 随机访问：读取很少量的数据，例如4KB
  - $T_{seek}$ + $T_{rotate}$ 起主要作用
  - 每次随机访问~10ms，每秒进行100次访问
  - 例如：随机访问4KB数据，那么400KB/s
- 顺序访问：读大量的数据，例如>1MB
  - $T_{transfer}$ 起主要作用
  - 速度取决于盘片转速、磁介质密度、硬盘接口带宽限制
  - ~100MB/s
- 优化目标：尽量使用顺序访问



## 硬盘（HDD）

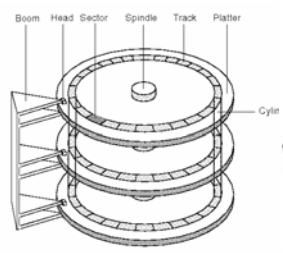


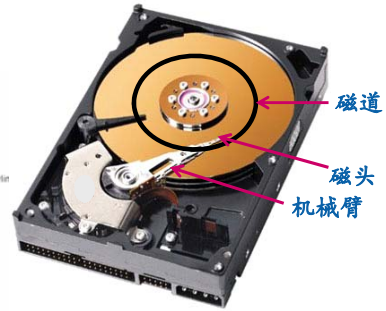


- 磁盘控制器
  - 控制机械臂的移动，完成读写
  - 实现外设接口协议：例如SATA, SCSI, 或PCI
  - 通常含有一定的缓冲区（10~100MB大小）
  - 实现了磁盘请求调度（对于一组请求按什么顺序完成？）



## 闪存(Flash)与固态硬盘(SSD: Solid State Drive)

- 闪存
  - 发明于1980年，与DRAM技术有一定的相似性
  - 最早用于取代ROM作BIOS存储
  - 后来用于数字电子设备：相机、手机、mp3、U盘、microSD卡等，大量生产，价格降低
- 固态硬盘
  - 2009年开始出现以闪存为存储介质的固态硬盘


SATA


PCI-E

## Flash

- Flash(闪存)的单元结构与DRAM(内存)相似
  - DRAM：电容存储电荷，表示0/1
  - Flash：用一个Floating Gate(浮栅)结构，保持电荷

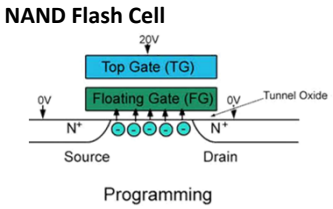




## 闪存(Flash) 写操作

- Flash不支持直接修改
- 擦除(Erasure)
  - 对大块数据操作（e.g.~1MB），设为同一状态（e.g.全1）
  - 擦除次数~5000次，之后无法再使用
- 写(Write)
  - 对一页（e.g.4KB）进行操作，只能单向修改（例如1->0）
- 所以，SSD中都有FTL（Flash Translation Layer）
  - 把逻辑地址映射为内部的物理地址
  - 磨损均衡（Wear-Leveling）
  - 内部有比较复杂的管理算法
- 随机写操作，性能差
  - 而且会使SSD总体性能变差，这是因为映射与磨损均衡不是完美的



## 闪存(Flash)读操作

- 读操作
  - 相对简单
- 随机读操作，性能很好
  - ~10000次/s，是机械硬盘的100倍
- 顺序读写，可以利用内部多个Flash芯片的并行性
  - 也可以达到很好的性能
  - 300MB~1GB/s



## 新型的非易失存储（NVM）技术


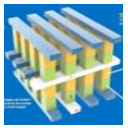

- 集成电路特征尺寸已经接近极限
  - 当前的特征尺寸是7纳米
  - DRAM每个比特依靠存储电荷来区别0/1
  - 特征尺寸变小➔存储电荷数变少➔稳定性变差
- 业界在研发新型的存储技术来替代DRAM
  - Phase Change Memory，STT-RAM，Memristor
  - 3D-Xpoint（预期2018年发售）
  - 也被称为Persistent Memory (PM)
- 性能特征
  - 非易失：不需要定时刷新，节能，可靠
  - 访问延时：DRAM < NVM << Flash
  - 读写粒度< I/O界面，应该类似于DRAM
  - 读比写快

## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
  - 存储层次
  - 存储介质：磁盘、固态硬盘等
  - 磁盘阵列
  - 操作系统支持
  - 存什么？
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理



## 磁盘阵列（Disk Array）

- 用多个磁盘组成一个磁盘阵列
- 对外提供统一的一个块操作界面
- 内部通过多个磁盘实现
  - 数据冗余+容错，并行访问提高性能
- 注意：阵列可以从机械硬盘推广

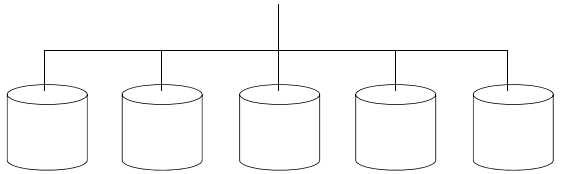



## RAID

- Redundant Array of Independent Disks

- RAID levels：不同的结构
  - RAID 0
  - RAID 1
  - RAID 5
  - RAID 0+1
  - RAID 10 (即RAID 1+0)
  - RAID 50 (即RAID 5+0)



## RAID 0

- Striping
  - stripe unit: 例如64KB
  - 想象所有磁盘空间都分解为64KB大小的对齐的块
  - 那么，全局的第N块
    - 在第 N % num_disks 个磁盘上（磁盘从0号开始）
    - 在磁盘内部是 第N / num_disks块（块从第0块开始）
  - 例如：num_disks= 2
  - 那么全局第 103块在哪里？

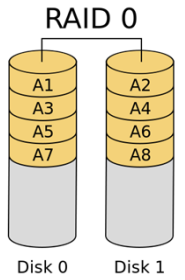


图像来源：wikipedia

## RAID 0

- Striping
  - stripe unit: 例如64KB
  - 想象所有磁盘空间都分解为64KB大小的对齐的块
  - 那么，全局的第N块
    - 在第 N % num_disks 个磁盘上（磁盘从0号开始）
    - 在磁盘内部是 第N / num_disks块（块从第0块开始）
  - 例如：num_disks= 2
  - 那么全局第 103块在哪里？
    - 103 % 2 = 1，在磁盘1上
    - 103/2 = 51，在盘内块51的位置

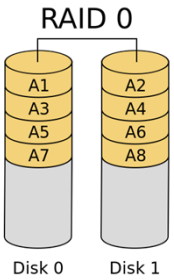


图像来源：wikipedia



## RAID 0

- Striping
  - 如何顺序读？
  - 如何顺序写？
  - 如何随机读？
  - 如何随机写？
  - 如何恢复？

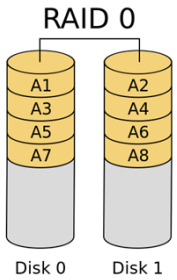


图像来源：wikipedia



## RAID 0

- Striping
  - 假设由K个硬盘组成（图中K=2）
  - 如何顺序读？
  - 如何顺序写？
    - 映射为所有K个硬盘的顺序访问
    - 一个顺序访问操作在K个硬盘上同时运行，可以获得K倍的传输带宽
  - 如何随机读？
  - 如何随机写？
    - 映射为单块硬盘的随机访问
    - 可以并发同时支持K个随机访问
    - 要求随机访问不是映射到同一个盘
  - 如何恢复？
    - 不支持

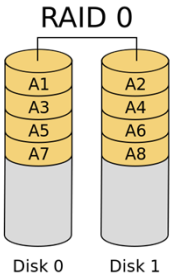


图像来源：wikipedia



## RAID 0

- Striping
  - 优点
    - 随机访问时：可能同时访问多个盘
    - 顺序访问时：发挥多个盘的总带宽
    - 利用所有存储空间
  - 缺点
    - 不提供数据冗余
    - 如果磁盘坏了，那么数据丢失

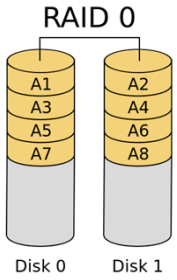


图像来源：wikipedia

## RAID 1

- Mirroring（镜像）
  - K个硬盘存储完全一样的数据
  - 图中K=2
  - 如何顺序读？
  - 如何顺序写？
  - 如何随机读？
  - 如何随机写？
  - 如何恢复？

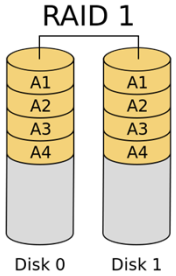


图像来源：wikipedia



## RAID 1

- Mirroring（镜像）
  - K个硬盘存储完全一样的数据
  - 图中K=2
  - 如何顺序读？
    - 数据在每个盘上都有
    - 可以K个硬盘并行读，获得K倍带宽
  - 如何随机读？
    - 每个盘都可以支持任何的随机读
    - 可以并发支持K个随机读
  - 如何顺序写？随机写？
    - 每个盘都进行相同的写操作
    - 写K倍的数据
  - 如何恢复？
    - 只要一个盘工作就有所有数据
    - 插入一块替换新硬盘，然后复制全盘即可

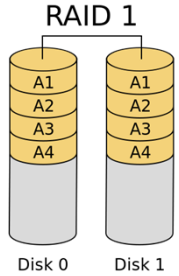


图像来源：wikipedia



## RAID 1

- Mirroring（镜像）
  - 优点
    - 数据冗余：而且恢复速度快
    - 读操作：可以并行执行
  - 缺点
    - 写操作：要写K个盘
    - 总体空间利用率只有1/K

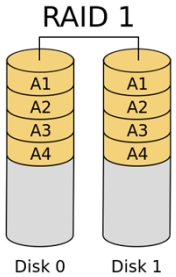


图像来源：wikipedia



## RAID 5

- RAID 5：希望既提供冗余，又提高空间利用率
  - 采用Parity（异或）校验一组Stripe Unit
  - Parity块轮流放置在不同的硬盘上

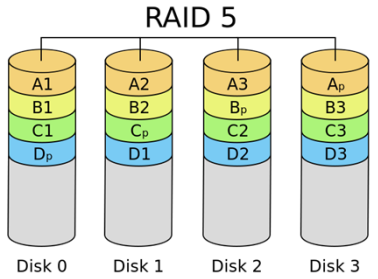


图像来源：wikipedia

## Parity（又称为奇偶校验）

- 盘1: 0001
- 盘2: 0110 ⊕
- 盘3: 1001 ⊕
- Parity: 1110（奇数个1为1，偶数个1为0）

- 假设盘3坏了，那么可以通过计算得到
  - 0001 ⊕ 0110 ⊕ 1110 = 1001
  - 于是就可以恢复盘3的数据



## RAID 5

- 如何顺序读？
- 如何顺序写？
- 如何随机读？
- 如何随机写？
- 如何恢复？

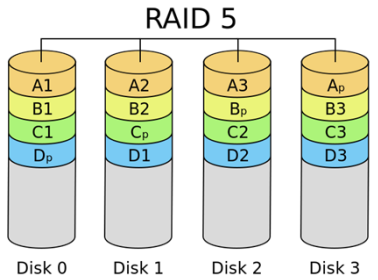


图像来源：wikipedia



## RAID 5

- 如何顺序读？随机读？
  - 有些像RAID0
  - 可以利用K-1个盘的带宽支持顺序读
  - 可以并发支持K个随机读（为什么不把Parity存在一个盘上？）
- 如何顺序写？随机写？
  - 每写一个Stripe Unit要写2个磁盘：数据+Parity；为了计算Parity要读2个盘（旧数据和旧Parity）
- 如何恢复？
  - 1个盘坏了
  - 插入一个替换新盘
  - 读K-1个盘，计算得到新盘中应该存储的数据

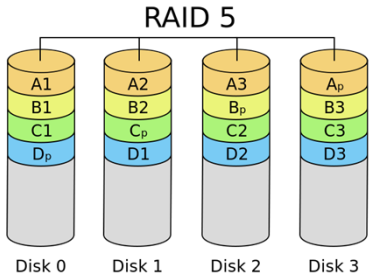


图像来源：wikipedia



## RAID 5

- 优点
  - 校验和冗余：可以处理一个磁盘损坏的情况
  - 读操作：可以发挥并行性
- 缺点
  - 写操作要重新计算Parity
    - 写原始块和Parity块
  - 恢复时，要读所有的磁盘才能恢复，代价大

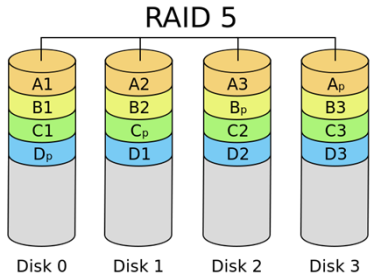


图像来源：wikipedia

## RAID 6

- 与RAID5相似，只是每组stripe units产生了多个Parity块
  - 所以可以修复多块磁盘损坏的情况
- k个Parity块最多可以支持$2^k$-1-k块磁盘，容忍k-1个坏盘

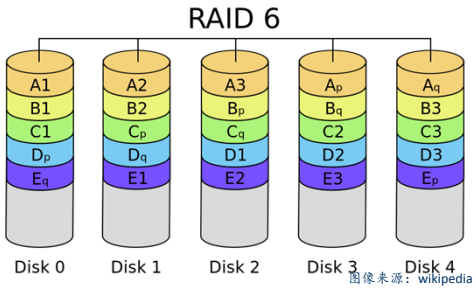


图像来源：wikipedia



## RAID

- RAID levels：不同的结构
  - RAID 0
  - RAID 1
  - RAID 5
  - RAID 6
  - RAID 0+1
  - RAID 10 (即RAID 1+0)
  - RAID 50 (即RAID 5+0)

两种RAID的复合



## RAID 0+1

- 下层是RAID0，上面是RAID1

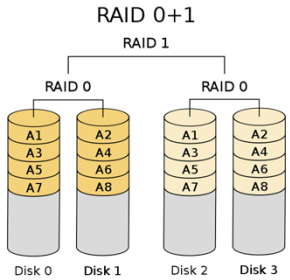


图像来源：wikipedia



## RAID 1+0

- 下层是RAID1，上面是RAID0

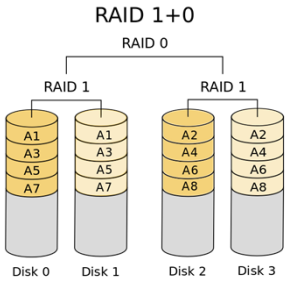


图像来源：wikipedia

## RAID 5+0

- 下层是RAID5，上面是RAID0

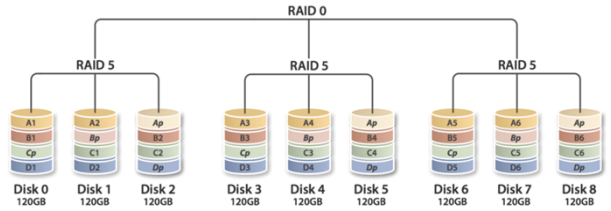


图像来源：wikipedia



## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
  - 存储层次
  - 存储介质：磁盘、固态硬盘等
  - 磁盘阵列
  - 操作系统支持
  - 存什么？
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理



## 本地文件系统 (Local File System)

- 例子： Linux ext4, Windows ntfs, Mac OS hfs …

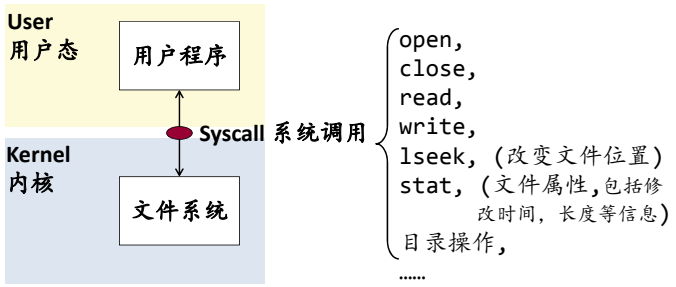




## 块设备

- 可以直接打开Raw Partition

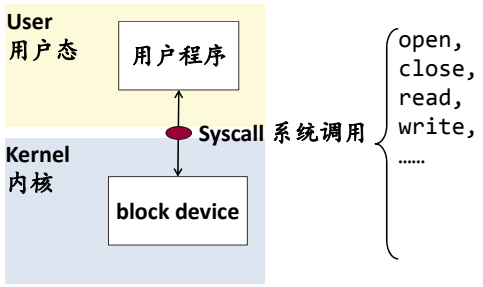

## 数据库 vs. 文件系统（数据存储角度比较）

- 文件系统
  - 存储文件(file)
  - 通用的，存储任何数据和程序
  - 文件是无结构的，是一串字节组成的
  - 操作系统内核中实现
  - 提供基本的编程接口
    - Open, close, read, write
- 数据库
  - 存储数据表(table)
  - 专用的，针对关系型数据进行存储
  - 数据表由记录组成，每个记录由多个属性组成
  - 用户态程序中实现
  - 提供SQL接口
- 共同点
  - 数据存储在外存（硬盘）
  - 根据硬盘特征，数据分成定长的数据块



## 数据在硬盘上的存储

- 硬盘最小存储访问单位为一个扇区：512B
- 文件系统访问硬盘的单位通常为：4KB
- RDBMS最小的存储单位是database page size
  - Data page size 可以设置为1~多个文件系统的 page
  - 例如，4KB, 8KB, 16KB, …
  - 我们下面用page简称database page



## 数据在硬盘上的存储

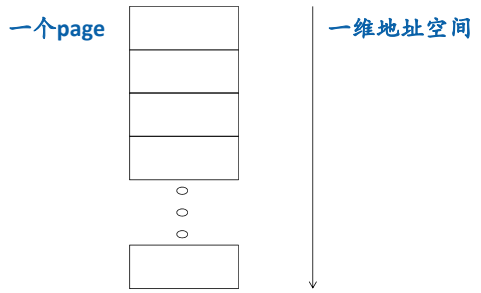


- Raw partition或file
- 如果使用file
  - 每个Table可以是自己的文件，也可以使用一个大文件里面分成多个Table



## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
  - 存储层次
  - 存储介质：磁盘、固态硬盘等
  - 磁盘阵列
  - 操作系统支持
  - 存什么？
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理

## 存储在硬盘上的内容：记录文件

- 记录数据Table
  - 行式存储，或者列式存储
- 行式存储的堆文件
  - 记录是无序的
  - 多条记录组成数据页
  - 文件由多个数据页组成
- 排序文件
  - 记录按照某个顺序排序
- 支持插入、删除、修改



## 存储在硬盘上的内容：索引

- 索引结构
  - 树结构索引
  - 哈希索引
- 聚簇？数据页与索引的顺序一致吗？
  - 聚簇索引（Clustered Index）：顺序一致
  - 二级索引（Secondary Index）：顺序不一致

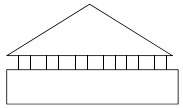

Clustered

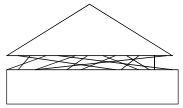

Non-Clustered
又称作Secondary



## 存储在硬盘上的内容：其它

- System catalog
  - 包含database, table, view, index等的定义
  - 包含一些统计信息，用以优化查询
- Log：日志
  - Transactional log：为了事务处理ACID所使用的log
  - Operation log：每个处理操作的记录



## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
- 硬件和操作系统支持
- 磁盘空间管理
  - 概念
  - 工作原理
- 记录文件格式
- 缓冲区管理

## 比照内存中的malloc/free

- malloc/free
  - 通过mmap/sbrk等从操作系统分配新的大块内存
  - 把大块内存分解为小的内存块
  - 根据应用程序中malloc分配的大小，找到合适的块
  - 完成分配与释放



## 在磁盘上需要进行空闲块的管理

- 方法1：数据库自己管理空间
  - 下层存储是Raw Partition，磁盘分区
  - 或者使用一个大文件，内部自行管理
- 记录数据块是否空闲
  - 空闲块列表
  - 或者空闲块位图（Bitmap）
    - 0代表空闲，1代表使用
- 完成数据块分配与释放功能
- 进一步，每个Table或Index需要记录所使用的Page



## 在磁盘上需要进行空闲块的管理

- 方法2：依托操作系统的文件系统来管理
  - 数据库的每个Table或Index存成单独的文件
  - 下层文件系统具体对磁盘的空闲块进行管理
  - 现在用得比较多
    - 因为文件系统已经相当稳定，性能也很高



## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
- 硬件和操作系统支持
- 磁盘空间管理
- 记录文件格式
  - 行式文件页结构
  - 行式记录结构
  - 列式文件结构
  - 顺序读和I/O模型
- 缓冲区管理

# 行式记录结构

- 定长的列
  - 数值类型：整数、浮点数等
  - 定长字符串：char(n)
  - 时间日期等
- 变长的列
  - 变长字符串：varchar(n)
  - 变长二进制对象：BLOB (Binary Large OBject) 等
- 怎么设计通用的数据结构？

| ID | Name | Birthday | Gender | Major | Year | GPA |
|---|---|---|---|---|---|---|
| 131234 | 张飞 | 1995/1/1 | 男 | 计算机 | 2013 | 85 |



# Tuple的结构

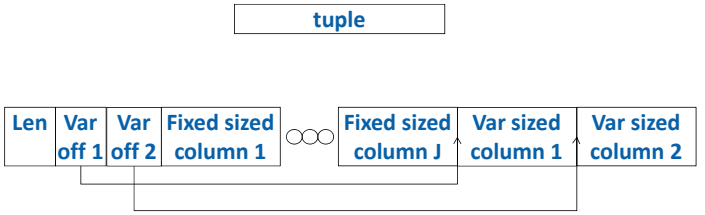


- 举例：有两个变长的列



# 举例

| ID | Name | Birthday | Gender | Major | Year | GPA |
|---|---|---|---|---|---|---|
| 131234 | 张飞 | 1995/1/1 | 男 | 计算机 | 2013 | 85 |

```
create table Student (
        ID integer NOT NULL, Name varchar(20), Birthday date,
        Gender enum(M, F), Major varchar(20), Year year, GPA float,
        primary key (ID));
```

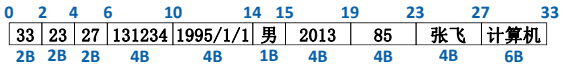




# Tuple要存储在Page中

- 那么如何设计Page中的结构？
- 简单想法
  - 一条接着一条地存Tuple
- 问题
  - 如何支持记录的随机访问？
  - Insert, delete, update怎么办？

## Page内部结构（Slotted Page）

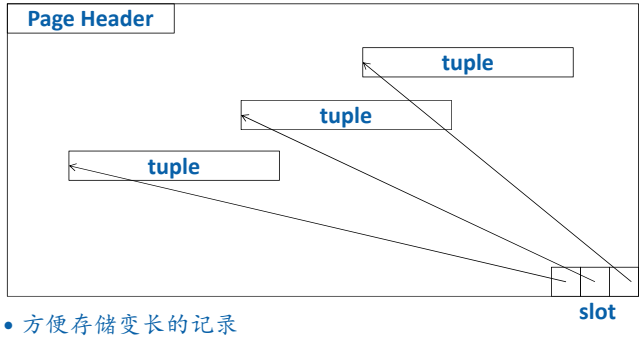


- 方便存储变长的记录
- 记录超出页面大小就需要特殊处理
- Page Header包含：PageID, 校验和, LSN(事务日志序号)等



## Page内部结构（Slotted Page）

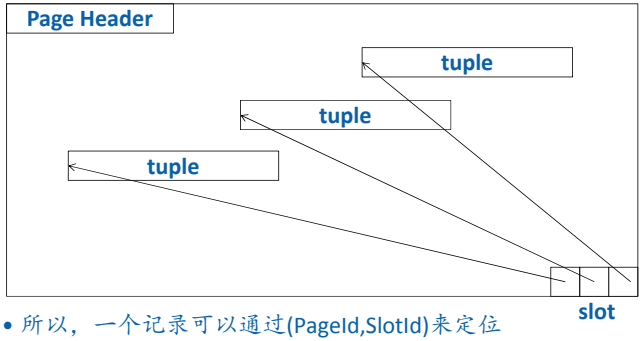


- 所以，一个记录可以通过(PageId,SlotId)来定位
- 在一些系统中，RecordId就是这两部分的结合



## 跨块记录

- 当记录比一个数据页大时
- 分为多个子记录，存储在不同的数据页中
- 多个子记录之间互相指向

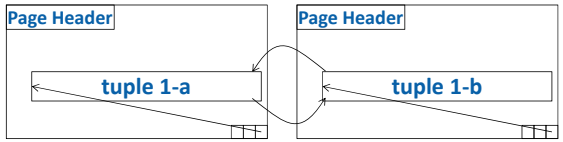




## Insertion

- 无序的堆文件
  - 找到一个具有足够空间的Page
  - 插入新记录
- 排序文件
  - 找到该记录应该放置的Page
  - 如果此Page中有足够的空间，那么直接插入新记录
    - 可以移动Page中现有的记录，来获得完整的空闲空间
  - 如果空间不够
    - 在邻近Page中找空间，移动记录
    - 把当前Page分裂为两个Page，Page header包含溢出块的地址

## Deletion

- 找到对应的Page
- 删除Page中的记录
- 有时需要保留对应的slot，记录一个删除标记
  - 从而保证这个RecordId不被使用



## Update

- 如果修改不使原记录变大
  - 那么就在原记录位置修改
- 如果会变大，那么就遇到与插入相似的问题
  - 当前Page有足够空间时，可以通过移动Page内部的Tuple来得到一片连续的空间放置记录
  - 当前Page没有足够的空间时，就需要考虑邻近Page或溢出



## 数据的顺序访问

```
select Name, GPA
from Student
where Major = '计算机';
```

- 顺序读取Student表的每个page
- 对于每个page，顺序访问每个tuple
- 检查条件是否成立
- 对于成立的读取Name和GPA



## 计算I/O模型

- 当一个操作中I/O的开销为主导地位时
- 考虑磁盘I/O次数（访问Page的个数）来近似算法时间

# 数据的顺序访问的I/O代价

```
select Name, GPA
from Student
where Major = '计算机';
```

- 假设Student表有M个Page
- 那么前述顺序访问的代价就为M



# 列式数据存储

- 每个列产生一个文件，存储所有记录中该列的值

| ID | Name | Birthday | Gender | Major | Year | GPA |
|---|---|---|---|---|---|---|
| 131234 | 张飞 | 1995/1/1 | 男 | 计算机 | 2013 | 85 |
| 145678 | 貂蝉 | 1996/3/3 | 女 | 经管 | 2014 | 90 |
| 129012 | 孙权 | 1994/5/5 | 男 | 法律 | 2012 | 80 |
| 121101 | 关羽 | 1994/6/6 | 男 | 计算机 | 2012 | 90 |
| 142233 | 赵云 | 1996/7/7 | 男 | 计算机 | 2014 | 95 |

存储为7个列文件

| ID |
|---|
| 131234 |
| 145678 |
| 129012 |
| 121101 |
| 142233 |

| Name |
|---|
| 张飞 |
| 貂蝉 |
| 孙权 |
| 关羽 |
| 赵云 |

| Birthday |
|---|
| 1995/1/1 |
| 1996/3/3 |
| 1994/5/5 |
| 1994/6/6 |
| 1996/7/7 |

| Gender |
|---|
| 男 |
| 女 |
| 男 |
| 男 |
| 男 |

| Major |
|---|
| 计算机 |
| 经管 |
| 法律 |
| 计算机 |
| 计算机 |

| Year |
|---|
| 2013 |
| 2014 |
| 2012 |
| 2012 |
| 2014 |

| GPA |
|---|
| 85 |
| 90 |
| 80 |
| 90 |
| 95 |



# 为什么要用列式存储？

- 数据库的分析查询
  - 大部分情况只涉及一个表的少数几列
  - 会读一大部分记录
- 在这种情况下，行式存储需要读很多无用的数据
- 采用列式存储可以降低读的数据量

| ID | Name | Birthday | Gender | Major | Year | GPA |
|---|---|---|---|---|---|---|
| 131234 | 张飞 | 1995/1/1 | 男 | 计算机 | 2013 | 85 |
| 145678 | 貂蝉 | 1996/3/3 | 女 | 经管 | 2014 | 90 |
| 129012 | 孙权 | 1994/5/5 | 男 | 法律 | 2012 | 80 |
| 121101 | 关羽 | 1994/6/6 | 男 | 计算机 | 2012 | 90 |
| 142233 | 赵云 | 1996/7/7 | 男 | 计算机 | 2014 | 95 |



# 列式存储的压缩

- 每个文件存储相同数据类型的值
- 数据更容易被压缩
- 比行式存储有更高的压缩比

| Year |
|---|
| 2013 |
| 2014 |
| 2012 |
| 2012 |
| 2014 |

**可以有多种简单的方法压缩**

## 顺序访问节省I/O

```
select Name, GPA
from Student
where Major = '计算机';
```

- 如果用到了一个表的多个列
- 多列需要拼装在一起，付出拼装代价

**但需要Join多列！**
所以，访问的列数影响性能

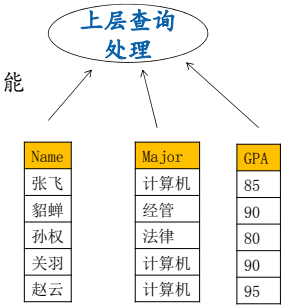


| Name |
|---|
| 张飞 |
| 貂蝉 |
| 孙权 |
| 关羽 |
| 赵云 |

| Major |
|---|
| 计算机 |
| 经管 |
| 法律 |
| 计算机 |
| 计算机 |

| GPA |
|---|
| 85 |
| 90 |
| 80 |
| 90 |
| 95 |



## Outline

- 数据库系统内部架构概述
- 数据存储与访问路径概述
- 硬件和操作系统支持
- 磁盘空间管理
- 记录文件格式
- 缓冲区管理



## 什么是Buffer Pool?

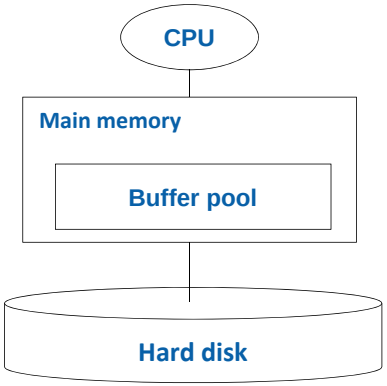


**为什么需要Buffer pool?**
**每次访问直接读写硬盘会有什么问题吗?**

**提高性能，减少I/O**



## 数据访问的局部性(locality)

- Temporal locality (时间局部性)
  - ❑ 同一个数据元素可能会在一段时间内多次被访问
  - ☞ Buffer pool
- Spatial locality (空间局部性)
  - ❑ 位置相近的数据元素可能会被一起访问
  - ☞ Page为单位读写

## Buffer Pool的组成

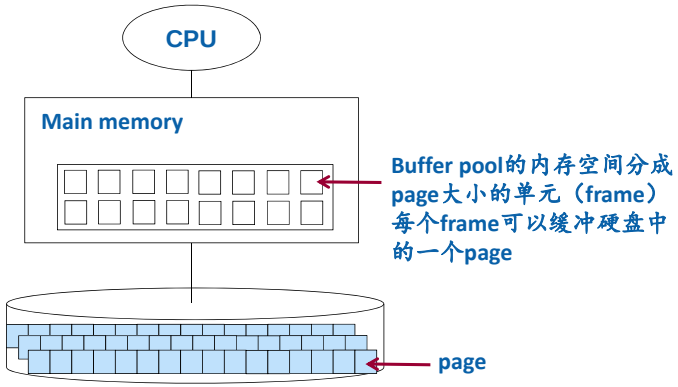




## Buffer Pool的内存结构

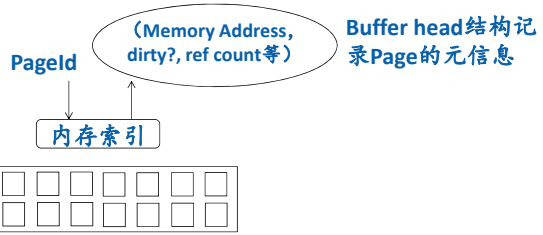


- 每次访问一个Page都需要查找PageId索引
- 如果存在，那么返回内存地址，进行访问
  - 增计ref count，根据是否是写操作请求，记录dirty状态



## 给定PageID=A，访问Page A的过程

- 查找索引，判断Page A是否在buffer pool之中
- 是：buffer pool hit
  - 直接访问buffer pool中的page
    - 节省了I/O操作
- 否：buffer pool miss
  - 在buffer pool中找到一个可用的frame ← 替换算法
  - 从硬盘读page A，放入这个frame



## Page Replacement (替换)

- 如果没有空闲的frame，那么怎么办？
- 需要找一个已缓存的page，替换掉
  - 这个page被称作Victim page
  - 如果这个page被修改过（dirty），那么需要写回硬盘
- 替换策略？（如何选择Victim?）
  - 目标：尽量减少I/O代价，希望Victim在近期不可能被访问
  - 算法：通常是LRU（Least Recently Used）的某种变形

## Replacement Policies(替换策略)

- 操作系统课应该讲，常见的替换策略有
  - Random：随机替换
  - FIFO(First In First Out)：替换最老的页
  - LRU (Least Recently Used)：最近最少使用
- 我们围绕LRU介绍数据库中常见的算法



## LRU（Least Recently Used）

- LRU的实现方法1

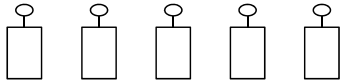

- Buffer head记录访问时间戳
- 替换：找到时间戳最早（小）的页为Victim
- 问题：每个替换操作检查N个Page,是O(N)!

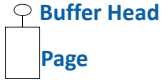




## LRU（Least Recently Used）

- LRU的实现2

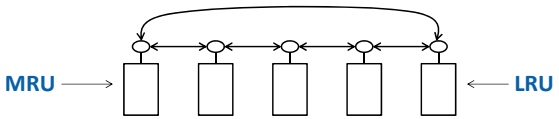





## LRU（Least Recently Used）

- LRU的实现2

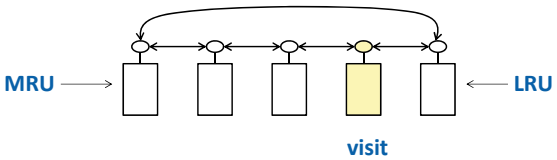


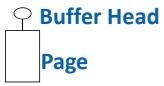

## LRU（Least Recently Used）

- LRU的实现2

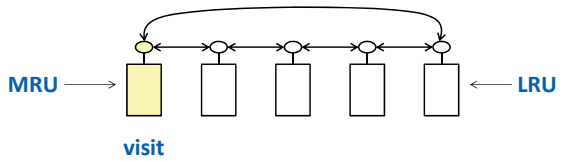


当一页被访问时，把它移动到最前端




## LRU（Least Recently Used）

- LRU的实现2

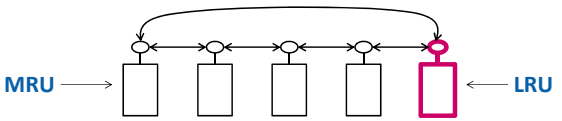


替换：总是选择最后一个Page为Victim
O(1)代价☺

但是：修改队列的代价，多线程共享队头




## Clock算法

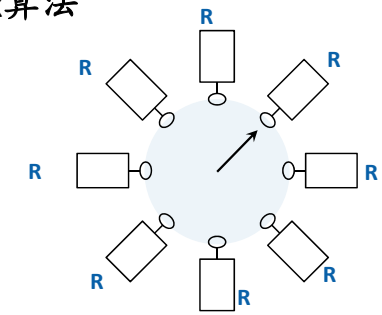


- 数据结构：Buffer head记录R，取值为0或1
  - R=1表示访问时间比较近期
  - R=0表示很长时间没有访问了



## Clock算法

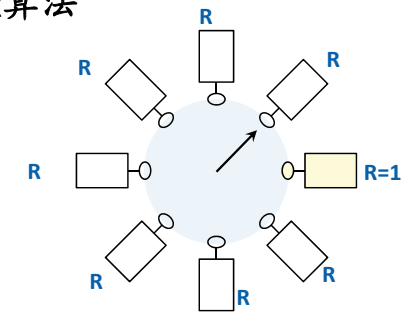


- 访问一个页：赋值R=1

## Clock算法

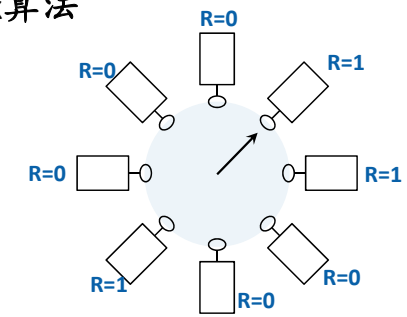


- 替换，顺时针旋转，依次查看下一个页
- if (R == 1) then {R=0; 继续旋转;}



## Clock算法

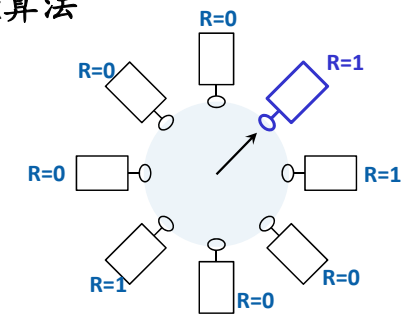


- 替换，顺时针旋转，依次查看下一个页
- if (R == 1) then {R=0; 继续旋转;}



## Clock算法

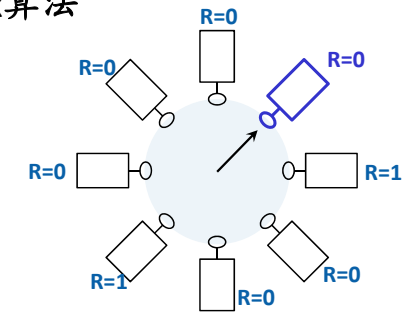


- 替换，顺时针旋转，依次查看下一个页
- if (R == 1) then {R=0; 继续旋转;}



## Clock算法

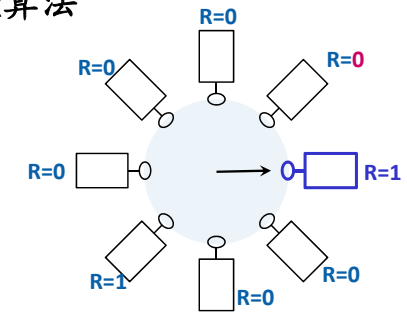


- 替换，顺时针旋转，依次查看下一个页
- if (R == 1) then {R=0; 继续旋转;}

## Clock算法

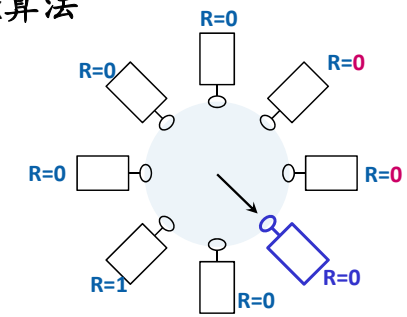


- 替换，顺时针旋转，依次查看下一个页
- if (R == 1) then {R=0; 继续旋转;}
- if (R == 0) then 选中为Victim



## Clock算法

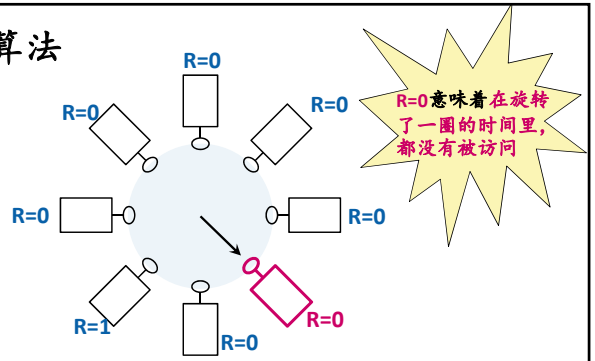


- 替换，顺时针旋转，依次查看下一个页
- if (R == 1) then {R=0; 继续旋转;}
- if (R == 0) then 选中为Victim



## 小结

- 数据库系统内部架构概述
- 数据存储与访问路径概述
  - 存储层次
  - 存储介质：磁盘、固态硬盘等
  - 磁盘阵列
  - 操作系统支持
  - 存什么？
- 磁盘空间管理：工作原理
- 记录文件格式
  - 行式文件页结构
  - 行式记录结构
  - 列式文件结构
  - 顺序读和I/O模型
- 缓冲区管理：工作原理，替换算法