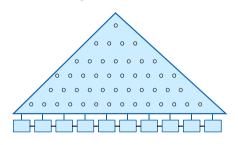


在B+-Tree中, key可以是多列拼接组成



- 例如: key=(姓名, 年龄)
 - 先比较第一部分, 完全相同时再比较第二部分
- 从本质上看,这仍然是单维的索引
 - 不同列的重要性不一样

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

单维索引的问题

- key = (姓名, 年龄)
- •如果只有年龄上的条件,怎么处理?□年龄=70,年龄>15□哈希表不能支持,B*-Tree很难支持

数据库系统

单维索引vs.多维索引

- 从本质上讲,上述索引是单维的
 - □B+-tree是按照一个顺序排列的
 - □ Hash table是按照一种方法来计算桶的下标的
 - □不同维度的重要性是不同的
- 多维索引
- □数据被认为存在于二维或更高维的空间中
- □每个维度具有相似的重要性

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

GIS中的典型查询类型

- 部分匹配
 - □指定一维或多维上的值, 查找匹配的对象
- 范围查询
 - □给出一维或多维上的范围, 查找匹配的对象
- 最近邻查询
 - □查找与给定点最近的点
- •下面, 我们考虑不同索引结构如何支持这些查询

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

多维索引应用场合

- •地理信息系统(Geographic Information System, GIS)
 - □通常是二维空间
 - □包含房屋, 道路, 桥梁, 湖泊等
- •集成电路设计
 - □毎层电路是一个二维空间
 - □多层组成三维空间
- 高维空间
 - □可以把文本的每个单词作为一个维度
 - □那么每个文本对应干高维空间的一个点
 - □我们这里介绍的多维索引主要适用于2维、3维等低维空间

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

传统索引表达多维空间

- 例如: 用B+-Tree对(x.v)坐标进行索引
 - □ (x, v) = (经度, 纬度)
- 有什么问题?
 - □部分匹配
 - 指定一维或多维上的值,查找匹配的对象
 - 如果指定y上的值,而x不指定,那么会怎么样?
 - □范围查询
 - 给出一维或多维上的范围, 查找匹配的对象
 - 如果仅给定v上的范围,那么会怎么样?
 - □最近邻香询
 - 查找与给定点最近的点?

数据库系统

Outline

- 多维索引
 - □概念
 - □多维散列索引
 - 网格文件 (Grid File)
 - 分段散列(Partitioned Hashing)
 - □多维树结构索引
- 物理数据库设计

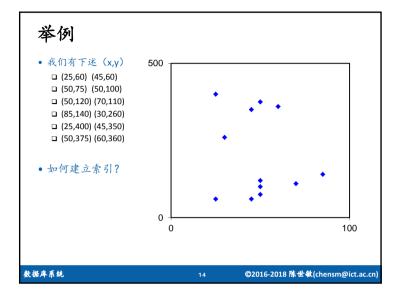
数据库系统

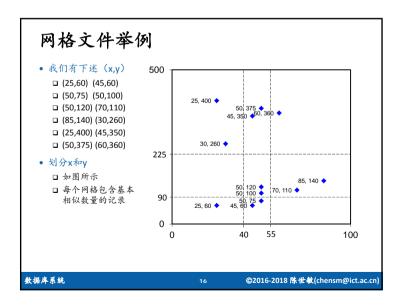
©2016-2018 陈世敏(chensm@ict.ac.cn)

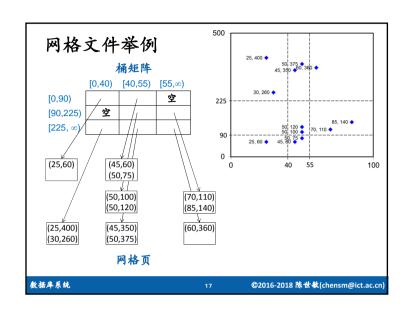
网格文件(Grid File)

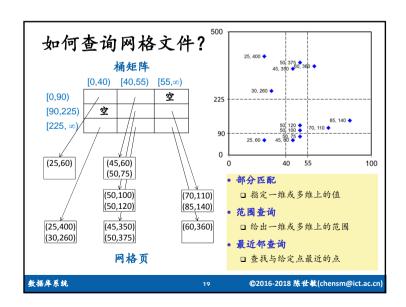
- 基本思想
 - □把整个空间切分成一个个长方形的网格
 - □每个网格→一个桶
 - □用一个数据结构记录桶的位置

数据库系统

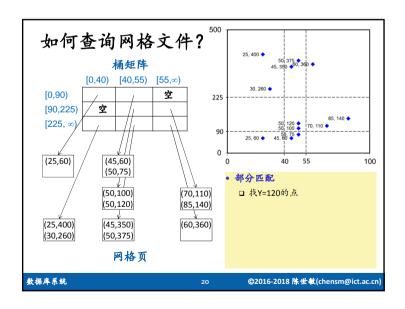


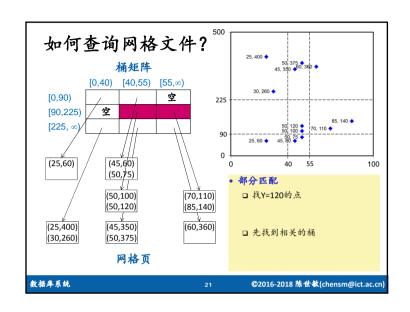


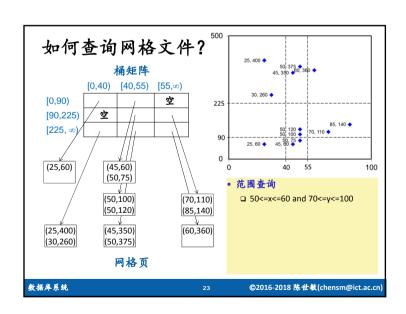


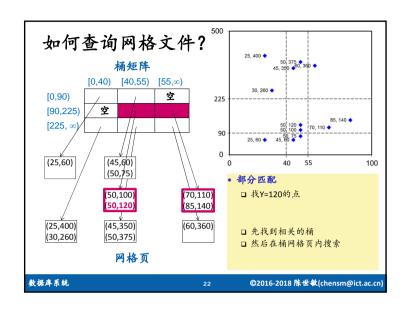


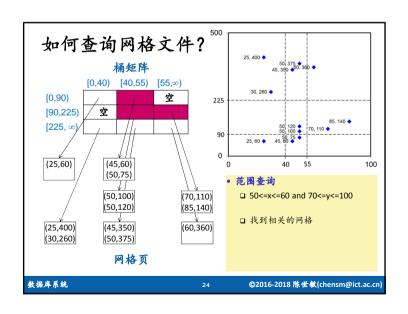
网格文件(Grid File) • 网格文件没有用hash function • 网格: 多维空间中的一个矩形空间 • 每维属性 □从小到大顺序排列, 切分为多个区间 第1维:有S,个区间: - 第2维: 有S₂个区间; - 第K维: 有S_v个区间 • 网格文件由下面两个数据结构组成 □ 桶矩阵: K维矩阵, S₁X S₂ X ... XSൂ个元素 - 每个矩阵元素对应一个网格 □每个矩阵元素记录网格的存储位置 - 该数据页包含这个网格中所有的索引项 - 如果数据页不够大,那么采用溢出链 数据库系统 ©2016-2018 陈世敏(chensm@ict.ac.cn)

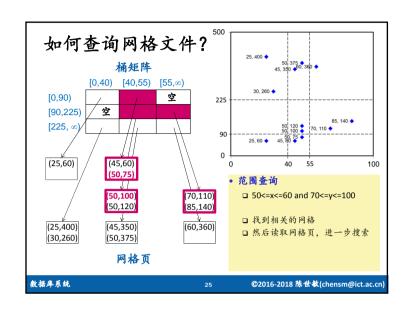


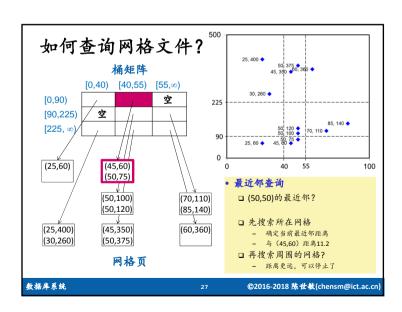


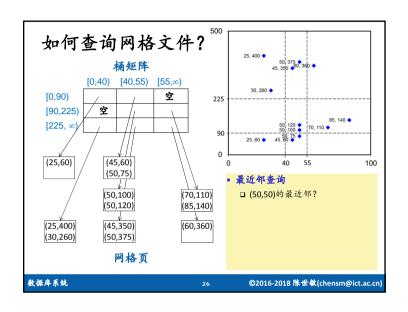


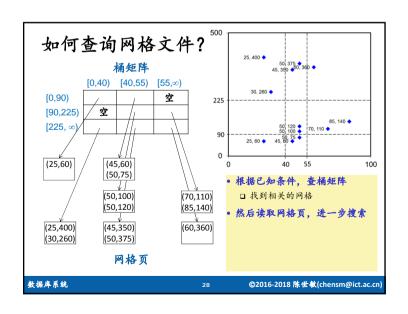


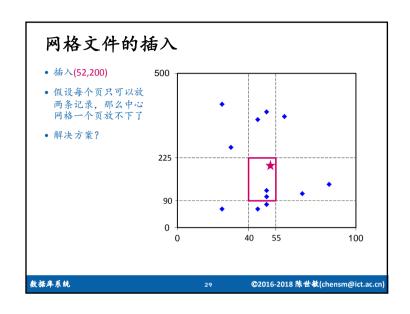


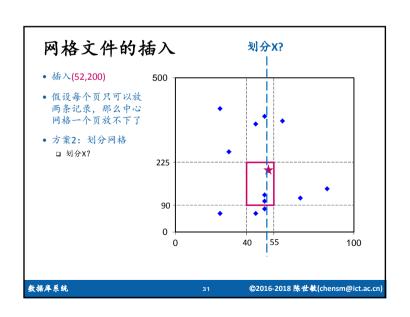


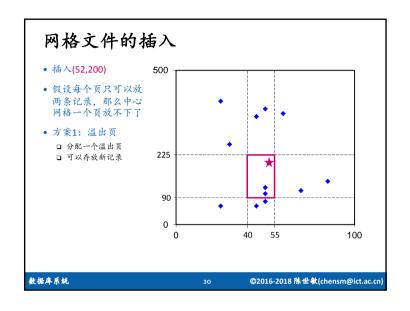


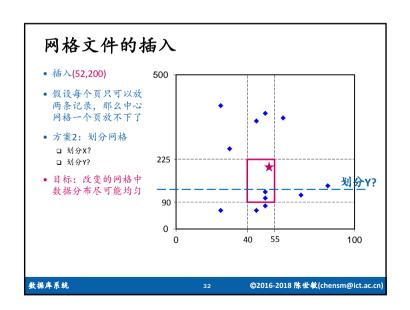












网格文件

- 网格文件算法的关键难点是需要确定
 - □给定一组数据,如何计算网格?
 - □插入数据时,如何划分网格?
- 我们这里不仔细介绍
 - □思路: 是否可以使用统计直方图?

数据库系统

33

©2016-2018 陈世敏(chensm@ict.ac.cn)

分段散列(Partitioned Hashing)

- 基本思想
 - □思考计算哈希函数、映射到桶这个过程
 - □使各个维度与桶能够分别对应?
 - 这样可以支持所需要的多维查找

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

Outline

- 多维索引
 - □概念
 - □多维散列索引
 - 网格文件 (Grid File)
 - 分段散列 (Partitioned Hashing)
 - □多维树结构索引
- 物理数据库设计

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

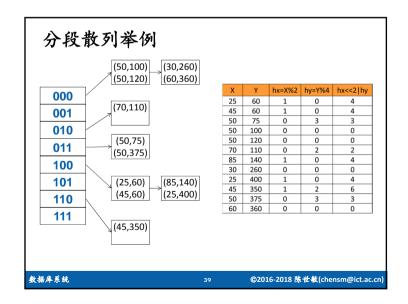
分段散列(Partitioned Hashing)

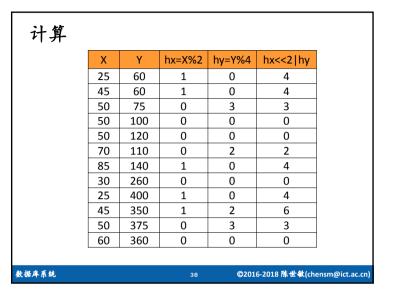
- 对于多维
 - □第1维,属性值key₁,计算哈希值h₁=hash₁(key₁)% Size₁
 - □第2维,属性值key₂,计算哈希值h₂=hash₂(key₂)%Size₂□
 - □第n维, 属性值key_n, 计算哈希值h_k=hash_n(key_n)% Size_n
- •注意: Size都是2的幂, 即取h(key)的一些bit
- 最终的哈希值为所有上述多个哈希值的拼接

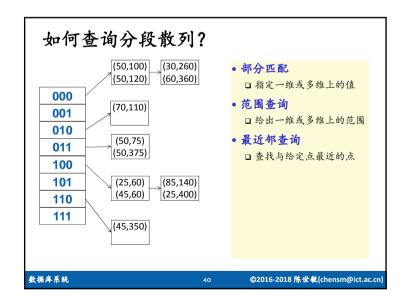
h₁ h₂ ... h_n

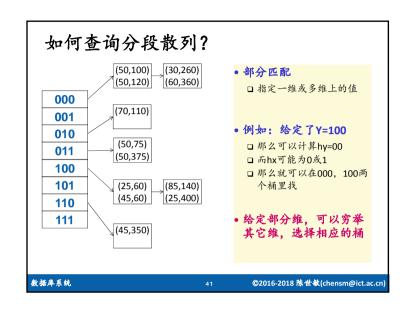
数据库系统

分段散列举例 我们有下述 (x,y) (25,60) (45,60) (50,75) (50,100) (50,120) (70,110) (85,140) (30,260) (25,400) (45,350) (50,375) (60,360) hx= x % 2 取x的1位hy= y % 4 取y的2位 h= (hx << 2) | hy 数据库系统 数据库系统

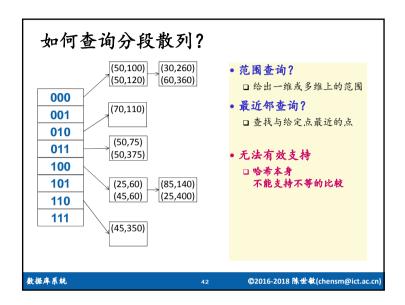








●查询 □ Partitioned Hashing 不支持范围查询和最近邻查询 ●数据结构 □ Partitioned Hashing很容易实现均匀地分布数据到桶中 □ Grid File则比较困难,尤其是当维数很高时,会出现大量的网格为空的情况

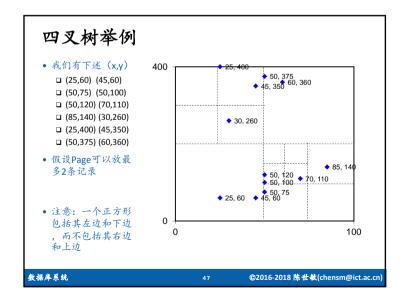


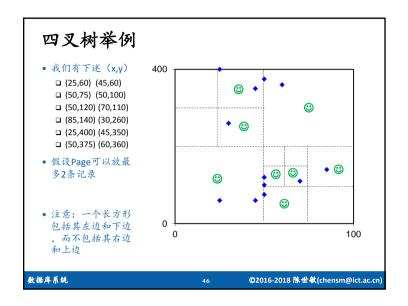


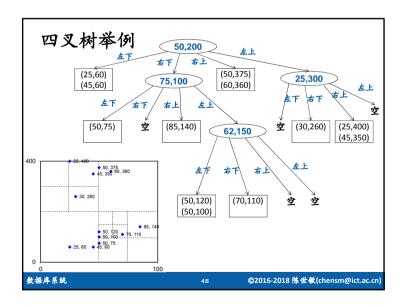
四叉树(Quad Tree)

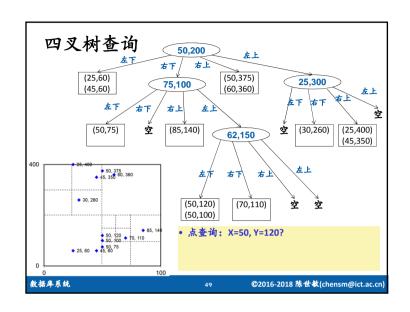
- 以二维为例
 - □每个树结点代表二维空间中的一个长方形
 - □内部结点等分为4个子长方形,对应4个孩子结点
 - □叶子节点?
 - 这个节点内部包含的记录点可以存放在一个页中
 - □内部节点?
 - 如果放不下,那么这个结点是内部结点
 - 需要进一步分成4个孩子节点

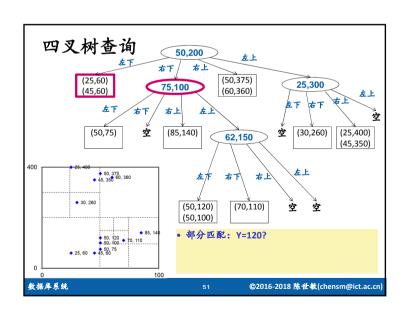
数据库系统

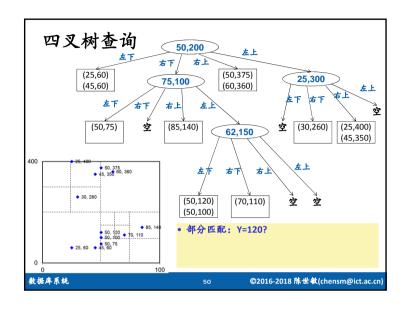


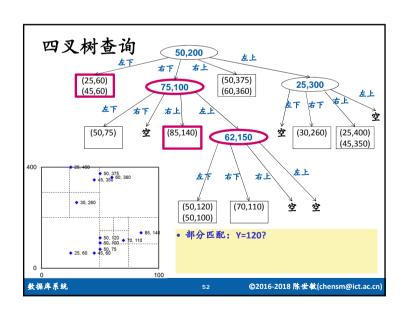


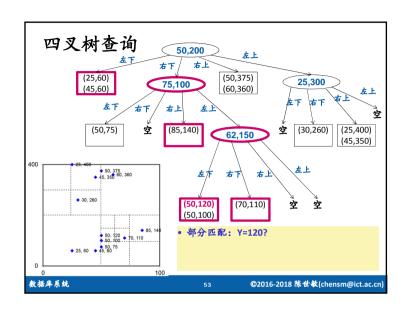


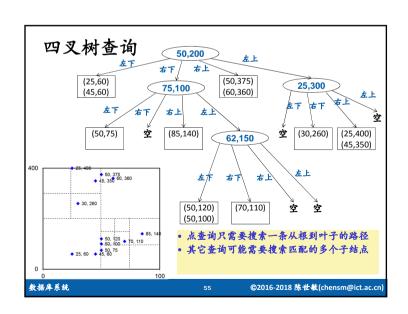


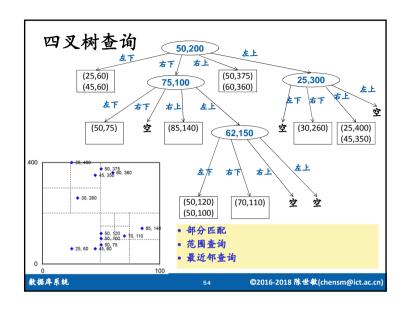


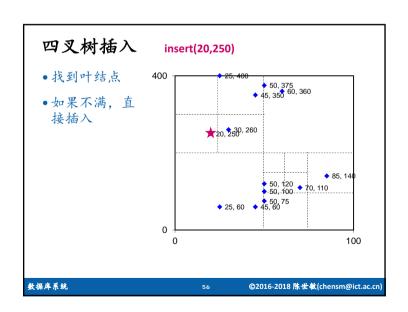


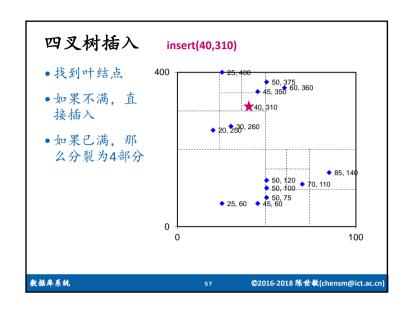












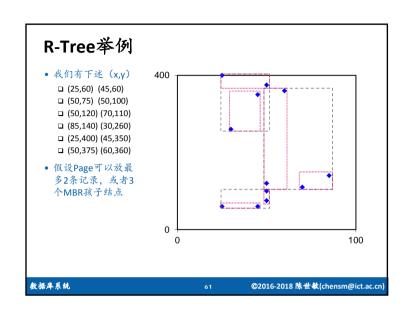


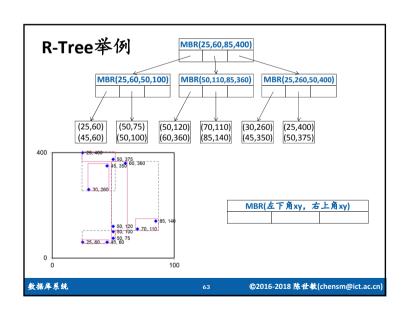
▶ k维 □每个树结点代表k维空间中的一个长方形 □内部结点长方形等分为2k个子正方形,对应2k个孩子结点 数据库系统 ©2016-2018 陈世載(chensm@ict.ac.cn)

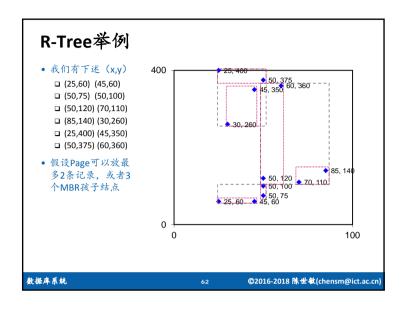
R树(R-Tree)

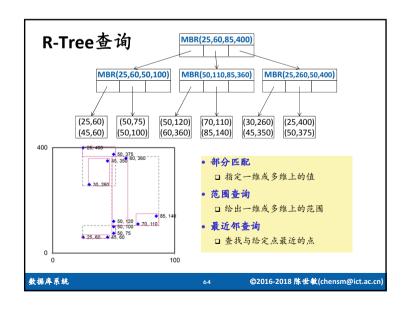
- 每个树结点代表一个区域
 - □称作MBR(Minimum Bounding Rectangle)
 - □是包含子树中所有对象的最小的外接矩形
- 两个树结点的MBR可能有重叠的区域
 - □希望使重叠的区域很小
 - □而B⁺-Tree的每个结点代表一个区间,区间之间不重叠 (当没有重复key时)

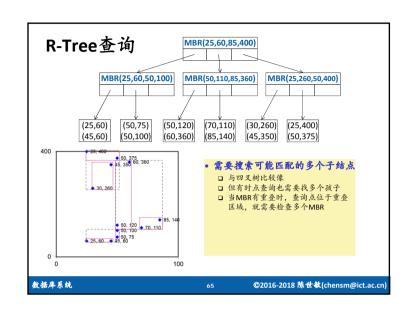
数据库系统 60 ©2016-2018 陈世敏(chensm@ict.ac.cn)













R-Tree建立和插入 • 关键问题是如何减少重叠区域? • 我们这里不进一步仔细讲解 • 思路: 采用启发式规则来减少重叠区域 数据库系统 ©2016-2018 陈世敏(chensm@ict.ac.cn)



方针1: 是否建立索引?

- 数据库系统自动建立的索引
 - ☐ Primary key, foreign key
- 用户建立索引
 - □目的: 快速获取满足某种过滤条件的记录
 - □只有where语句中涉及的列才需要索引
- 所以
 - □需要分析应用的需求,分析有哪些常见的查询
 - □ 最好一个索引有助于多个查询

数据库系统

9

©2016-2018 陈世敏(chensm@ict.ac.cn)

方针3:多属性索引Key

- 当Where语句中包含同一个表的多个属性
- •可以考虑单维索引+多个属性拼接为Key
- •注意索引中属性的次序

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

方针2:索引Key的选择、索引的种类

•索引Key是Where语句中出现的属性

□等值条件:哈希索引、B+-Tree等树结构索引

□范围选择: B+-Tree等树结构索引

(如果系统支持其他的索引结构)

- 当数据不进行update时,可以考虑Bitmap index
- •对于文本数据,可以考虑Inverted index
- 对干多维数据, 可以考虑多维索引

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

方针4: 是否聚簇(Clustered)索引

- 基本原则
 - □一个表只能按照一个索引进行聚簇 □其它索引都是二级索引
- 范围查询在聚簇上的收益最大

数据库系统

方针5: 平衡索引的开销

- 收益
 - □提高查询速度
- 开销
 - □空间开销:外存开销、内存开销
 - □时间开销:维护开销,当insert/delete/update时,相应的索引也必须被修改
- •选择恰当的索引和恰当的索引数量使在可以容忍的开销下,获得最大收益

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

辅助工具

- 可以选择的索引数量是指数级的
- •如何选择好的索引?
 - □人工:通过经验,建立索引,然后测试
 - 口辅助工具:例如, DB2 index advisor, Microsoft SQL Server Index Tuning Wizard
 - 通过一定的启发式规则,搜索可能的索引集合,估计其对查询的影响和开销,推荐一组索引

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

只需要索引就可以执行的查询

- 如果查询的所有列都在索引中可以找到
- •那么这个查询实际可以用索引来完成 (MS SQL Server)
- 例如

select count(*)

from *Student*

where *major*= "计算机";

如果在Student表上的major列上已经建立了索引,那么就可以直接在索引上完成count(*)的操作

数据库系统

©2016-2018 陈世敏(chensm@ict.ac.cn)

小结

- 多维索引
 - □概念
 - □多维散列索引
 - 网格文件 (Grid File)
 - 分段散列 (Partitioned Hashing)
 - □多维树结构索引
 - 四叉树(Quad Tree)
 - R树(R-Tree)
- 物理数据库设计
 - □索引的选择
 - □只需索引的查询
 - □索引选择的辅助工具

数据库系统